

Tarea 6

March 18, 2022

1 Curso de Optimización (DEMAT)

1.1 Tarea 6

Descripción:	Fechas
Fecha de publicación del documento:	Marzo 11, 2022
Fecha límite de entrega de la tarea:	Marzo 20, 2022

1.1.1 Indicaciones

Puede escribir el código de los algoritmos que se piden en una celda de este notebook o si lo prefiere, escribir las funciones en un archivo `.py` independiente e importar las funciones para usarlas en este notebook. Lo importante es que en el notebook aparezcan los resultados de las pruebas realizadas y que:

- Si se requieren otros archivos para poder reproducir los resultados, para mandar la tarea cree un archivo ZIP en el que incluya el notebook y los archivos adicionales.
- Si todos los códigos para que se requieren para reproducir los resultados están en el notebook, no hace falta comprimirlo y puede anexar sólo el notebook en la tarea del Classroom.
- Exportar el notebook a un archivo PDF y anexarlo en la tarea del Classroom como un archivo independiente. **No lo incluya dentro del ZIP**, porque la idea que lo pueda acceder directamente para poner anotaciones y la calificación de cada ejercicio.

1.2 Ejercicio 1 (5 puntos)

Programar el método de Newton con tamaño de paso fijo $\alpha = 1$.

La función recibe como parámetros la función que calcula el gradiente $g(x)$ de la función objetivo $f : \mathbb{R}^n \rightarrow \mathbb{R}$, la función que calcula la Hessiana $H(x)$ de f , un punto inicial x_0 , un número máximo de iteraciones N , y la tolerancia $\tau > 0$. Fijar $k = 0$ y repetir los siguientes pasos:

1. Calcular el gradiente g_k en el punto x_k , $g_k = g(x_k)$.
2. Si $\|g_k\| < \tau$, hacer $res = 1$ y terminar.
3. Si no se cumple el criterio, calcular la Hessiana $H_k = H(x_k)$.
4. Intentar calcular la factorización de Cholesky de H_k .
5. Si la factorización no se puede realizar, imprimir el mensaje de error, hacer $res = 0$ y terminar el ciclo.

6. Si se obtuvo la factorización, resolver el sistema de ecuaciones $H_k p_k = -g_k$ (esto da la dirección de descenso como p_k).
7. Calcular el siguiente punto de la secuencia como

$$x_{k+1} = x_k + p_k$$

8. Si $k + 1 \geq N$, hacer $res = 0$ y terminar.
9. Si no, hacer $k = k + 1$ y volver el paso 1.
10. Devolver el punto x_k , g_k , k y res .

Nota: Para calcular la factorización de Cholesky y resolver el sistema de ecuaciones puede usar las funciones `scipy.linalg.cho_factor` y `scipy.linalg.cho_solve`. Si la matriz no es definida positiva, la función `cho_factor` lanza la excepción `scipy.linalg.LinAlgError`. Puede usar esto para terminar el ciclo.

1. Programe la función que implementa el algoritmo del método de Newton, almacenando en una lista los puntos x_0, x_1, \dots, x_k que genera el algoritmo. Haga que la función devuelva esta lista.
2. Use la función de Rosenbrock, su gradiente y Hessiana para probar el algoritmo.
 - Use $N = 1000$, la tolerancia $\tau = \sqrt{\epsilon_m}$, donde ϵ_m es el épsilon de la máquina, y el punto inicial $x_0 = (-1.2, 1)$.
 - Si el algoritmo converge, imprima un mensaje que indique esto y genere una gráfica que muestre las curvas de nivel de la función f y la trayectoria de los puntos x_0, x_1, \dots, x_k . Para generar esta gráfica use una discretización de los intervalos $[-1.5, 1.5]$ en la dirección X y $[-1, 2]$ en la dirección Y .
 - Imprima el punto final x_k , $f(x_k)$, la magnitud del gradiente g_k y el número de iteraciones k realizadas.
 - Repita la prueba partiendo del punto inicial $x_0 = (-12, 10)$.

1.2.1 Solución:

```
[ ]: # En esta celda puede poner el código de las funciones
# o poner la instrucción para importarlas de un archivo .py
import numpy as np
from scipy.linalg import cho_solve, cho_factor
import itertools
import plotly.graph_objects as go
from IPython.core.display import Image, display

def newthon_method(gf, Hf, x_0, N, T):

    x_k = x_0
    k = 0
    res = 0
    points = [x_0]
    while (k < N):
```

```

    gf_k = gf(x_k)
    if np.linalg.norm(gf_k) < T:
        res = 1
        break
    Hf_k = Hf(x_k)
    try:
        p_k = cho_solve(cho_factor(Hf_k), -gf_k)
    except:
        break
    x_k = x_k + p_k
    points.append(x_k)
    k = k + 1

points = np.array(points)
return points, gf(x_k), k, res

def test(f, gf, Hf, x_0, N, T, xtl, xtr, ytl, ytr, p):
    points, g_k, k, res = newthon_method(gf, Hf, x_0, N, T)
    print(f"El algoritmo " + ("no " if res == 0 else "") + "convergió en:")
    x_k = points[-1]
    x_output = np.concatenate((x_k[0,:3], x_k[0,-min(3, len(x_k)-3):] if
↪ len(x_k) > 3 else []))
    print(f"k = {k}, ||g_k|| = {np.linalg.norm(g_k)}, x_k = {x_output}")
    fig = go.Figure()
    xtl = min(xtl, min(points[:,0,0]))
    xtr = max(xtr, max(points[:,0,0]))
    ytl = min(ytl, min(points[:,0,1]))
    ytr = max(ytr, max(points[:,0,1]))
    xtl, xtr = xtl - (xtr - xtl)/10, xtr + (xtr - xtl)/10
    ytl, ytr = ytl - (ytr - ytl)/10, ytr + (ytr - ytl)/10
    x = np.linspace(xtl,xtr,p)
    y = np.linspace(ytl,ytr,p)
    fig.add_contour(
        x=x,
        y=y,
        z=np.array([f(np.array([[x_i,y_i]])) for y_i, x_i in itertools.
↪ product(y,x)]).reshape(p,p),
        name='Rosenbrock'
    )
    fig.add_trace(
        go.Scatter(
            x = points[:,0,0],
            y = points[:,0,1],
            name='Newton'
        )
    )
    fig.update_layout(

```

```

        template="simple_white",
        title="Rosenbrock",
        width=500,
        height=500
    )
    #fig.show()

```

C:\Users\batma\AppData\Local\Temp\ipykernel_10500\2626011398.py:7:

DeprecationWarning:

Importing display from IPython.core.display is deprecated since IPython 7.14,
please import from IPython display

```

[ ]: # Pruebas realizadas a la función de Rosenbrock
def f(x):
    return 100*(x[0,1] - x[0,0]**2)**2 + (1 - x[0,0])**2

def gf(x):
    return np.array(
        [
            400*(x[0,0]**3-x[0,0]*x[0,1])+2*(x[0,0]-1),
            200*(x[0,1]-x[0,0]**2)
        ]
    )

def hf(x):
    return np.array(
        [
            [
                1200*x[0,0]**2-400*x[0,1]+2,
                -400*x[0,0]
            ],
            [
                -400*x[0,0],
                200
            ]
        ]
    )

```

```

[ ]: # Prueba realizada a la función del Ejercicio 1

x_0 = np.array([-1.2,1])
N = 1000
T = np.finfo(float).eps**(1/2)
xtl = -1.5
xtr = 1.5

```

```


ytl = -1
ytr = 2
p = 100
test(f, gf, hf, x_0, N, T, xtl, xtr, ytl, ytr, p)
display(Image("img/e_1_1.png"))
x_0 = np.array([-12,10])
test(f, gf, hf, x_0, N, T, xtl, xtr, ytl, ytr, p)
display(Image("img/e_1_2.png"))

```

El algoritmo convergió en:


$k = 6$, $||g_k|| = 8.285755243355701e-09$, $x_k = [1. \ 1.]$

Rosenbrock



El algoritmo convergió en:
 $k = 5$, $\|g_k\| = 0.0$, $x_k = [1. \ 1.]$

Rosenbrock



1.3 Ejercicio 2 (5 puntos)

Programar el método de Newton con tamaño de paso ajustado por el algoritmo de backtracking.

1. Modifique la función del Ejercicio 2 que implementa el algoritmo del método de Newton para incluir como parámetros a la función objetivo $f(x)$ y los parámetros ρ y c_1 del algoritmo de backtracking.
- Después de obtener la dirección de descenso p_k , calcular el tamaño de paso α_k usando como valor inicial $\bar{\alpha}_0 = 1$ en el algoritmo de backtracking.

- Hacer

$$x_{k+1} = x_k + \alpha_k p_k.$$

2. Repita la prueba del algoritmo, como se indicó en el Ejercicio 1, a la función de Rosenbrock, para ver como cambia la trayectoria de los puntos x_0, x_1, \dots, x_k en comparación con el resultado anterior, partiendo de $x_0 = (-1.2, 1)$ y de $x_0 = (-12, 10)$.

```
[ ]: # En esta celda puede poner el código de las funciones
# o poner la instrucción para importarlas de un archivo .py

def backtracking(f, f_k, gf_k, x_k, p_k, alpha, ro, c):
    while (f(x_k + alpha*p_k) > f_k + c*alpha*gf_k@p_k.T):
        alpha = ro*alpha
    return alpha

def newthon_method_backtracking(gf, Hf, x_0, alpha, ro, c, N, T):
    x_k = x_0
    k = 0
    res = 0
    points = [x_0]
    while (k < N):
        gf_k = gf(x_k)
        if np.linalg.norm(gf_k) < T:
            res = 1
            break
        Hf_k = Hf(x_k)
        try:
            p_k = cho_solve(cho_factor(Hf_k), -gf_k)
        except:
            break
        a_k = backtracking(f, f(x_k), gf_k, x_k, p_k, alpha, ro, c)
        x_k = x_k + a_k * p_k
        points.append(x_k)
        k = k + 1

    points = np.array(points)
    return points, gf(x_k), k, res

def test(f, gf, Hf, x_0, alpha, ro, c, N, T, xtl, xtr, ytl, ytr, p):
    points, g_k, k, res = newthon_method_backtracking(gf, Hf, x_0, alpha, ro,
↪c, N, T)
    print(f"El algoritmo " + ("no " if res == 0 else "") + "convergió en:")
    x_k = points[-1]
    x_output = np.concatenate((x_k[0,:3], x_k[0,-min(3, len(x_k)-3):]if
↪len(x_k) > 3 else []))
    print(f"k = {k}, ||g_k|| = {np.linalg.norm(g_k)}, x_k = {x_output}")
    fig = go.Figure()
```

```

xtl = min(xtl, min(points[:,0,0]))
xtr = max(xtr, max(points[:,0,0]))
ytl = min(ytl, min(points[:,0,1]))
ytr = max(ytr, max(points[:,0,1]))
xtl, xtr = xtl - (xtr - xtl)/10, xtr + (xtr - xtl)/10
ytl, ytr = ytl - (ytr - ytl)/10, ytr + (ytr - ytl)/10
x = np.linspace(xtl,xtr,p)
y = np.linspace(ytl,ytr,p)
fig.add_contour(
    x=x,
    y=y,
    z=np.array([f(np.array([[x_i,y_i]])) for y_i, x_i in itertools.
↳product(y,x)]).reshape(p,p),
    name='Rosenbrock'
)
fig.add_trace(
    go.Scatter(
        x = points[:,0,0],
        y = points[:,0,1],
        name='Newton'
    )
)
fig.update_layout(
    template="simple_white",
    title="Rosenbrock",
    width=500,
    height=500
)
#fig.show()

```

[]: *# Prueba realizada a la función del Ejercicio 1*

```


x_0 = np.array([[ -1.2,1]])
N = 1000
T = np.finfo(float).eps**(1/2)
xtl = -1.5
xtr = 1.5
ytl = -1
ytr = 2
p = 100
test(f, gf, hf, x_0, 1, 0.8, 0.0001, N, T, xtl, xtr, ytl, ytr, p)
display(Image("img/e_2_1.png"))
x_0 = np.array([[ -12,10]])
test(f, gf, hf, x_0, 1, 0.8, 0.0001, N, T, xtl, xtr, ytl, ytr, p)
display(Image("img/e_2_2.png"))

```

El algoritmo convergió en:

$k = 20$, $||g_k|| = 3.21430828407909e-11$, $x_k = [1. \ 1.]$

Rosenbrock



El algoritmo convergió en:

$k = 57$, $||g_k|| = 3.4893405656074994e-10$, $x_k = [1. \ 1.]$

Rosenbrock

