

# Métodos Estadísticos

## Tarea II

Rubén Pérez Palacios Lic. Computación Matemática  
Profesora: Dra. Eloísa Díaz Francés Murguía

22 de marzo de 2021

### Problemas

1. Considera una muestra de  $n$  variables aleatorias independientes  $X_1, \dots, X_n$  idénticamente distribuidas como exponencial con valor esperado  $\theta$ . Da las expresiones de una estadística suficientes  $t$  unidimensional para  $\theta$ . Usala para expresar la logverosimilitud  $l(\theta; t)$ , la función Score  $Sc(\theta; t)$  el emv de  $\theta$ , denotado como  $\hat{\theta}$ , la información observada de Fisher  $I_{\hat{\theta}}$  y finalmente la verosimilitud relativa de  $\theta$ , denotada como  $R(\theta; t)$ .

Recordemos que la función de densidad de una  $Exp(\theta)$  es

$$f(x; \theta) = \frac{1}{\theta} \exp\left(-\frac{x}{\theta}\right) \mathbb{1}_{[0, \infty)}(x),$$

por lo que función de distribución conjunto es

$$f(\vec{x}; \theta) = \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n \frac{1}{\theta} \exp\left(-\frac{x_i}{\theta}\right) \mathbb{1}_{[0, \infty)}(x_i) = \left(\prod_{i=1}^n \mathbb{1}_{[0, \infty)}(x_i)\right) \frac{1}{\theta^n} \exp\left(-\frac{\sum_{i=1}^n x_i}{\theta}\right),$$

por el Teorema de la factorización de Fisher tenemos que  $t = \sum_{i=1}^n x_i$  es una estadística suficiente de  $\theta$ .

Luego

$$L_U(\theta; t) = \frac{1}{\theta^n} \exp\left(-\frac{t}{\theta}\right),$$

por lo que

$$l(\theta; t) = \log\left(\frac{1}{\theta^n}\right) - \frac{t}{\theta},$$

entonces

$$Sc(\theta; t) = -\frac{n}{\theta} + \frac{t}{\theta^2},$$

igualando a cero la función Score obtenemos

$$0 = -\frac{n}{\hat{\theta}} + \frac{t}{\hat{\theta}^2},$$

por lo que

$$\hat{\theta} = \frac{t}{n} = \bar{X}.$$

La información de Fisher es

$$I_{\hat{\theta}} = \left( \frac{n}{\theta^2} - \frac{2t}{\theta^3} \right) \Big|_{\theta=\hat{\theta}} = \frac{n^3}{t^2}.$$

Por último la verosimilitud relativa es

$$R(\theta; t) = \frac{\frac{1}{\theta^n} \exp\left(-\frac{t}{\theta}\right)}{\frac{1}{\hat{\theta}^n} \exp\left(-\frac{t}{\hat{\theta}}\right)} = \left(\frac{t}{n\theta}\right)^n \exp\left(\frac{1}{n} - \frac{t}{\theta}\right).$$

2. Da un ejemplo de una distribución que pertenezca a la familia de distribuciones de valores extremos y también a la de localización y escala.

Es la distribución Gumbel. Sabemos que esta pertenece a la familia de distribuciones de valores extremos, ahora demostraremos que pertenece a la de localización y escala.

*Demostración.* Recordemos que la función de densidad de un Gumbel  $(a, b)$  es

$$f(x; a, b) = \frac{1}{b} \exp \left\{ -\frac{x-a}{b} - \exp \left[ -\left( \frac{x-a}{b} \right) \right] \right\} \mathbb{1}_{(-\infty, \infty)}(x).$$

Ahora podemos reexpresar esta como

$$f(x; a, b) = \frac{1}{b} f_0 \left( \frac{x-a}{b} \right),$$

donde

$$f_0(x) = \exp[-x - \exp(-x)] \mathbb{1}_{(-\infty, \infty)}(x).$$

Podemos ver que su soporte no depende de ningún parámetro desconocido. Además si  $Y = \frac{x-a}{b}$  entonces por el Teorema de Cambio de Variable su función de densidad es  $f_0(x)$  la cual no depende de ningún parámetro desconocido, por lo tanto concluimos que la Gumbel pertenece a la familia de localización y escala.  $\square$

3. La Densidad Gamma con parámetros de forma  $\alpha$  y escala  $\beta$  está dada como

$$f(x; \alpha, \beta) = \frac{x^{\alpha-1}}{\Gamma(\alpha) \beta^\alpha} \exp \left( -\frac{x}{\beta} \right) \mathbb{1}_{(0, \infty)}(x).$$

- a) Demuestra que la distribución Gamma pertenece a la familia exponencial de distribuciones.

*Demostración.* Podemos reexpresarla a la densidad de la distribución Gamma de la siguiente forma

$$f(x; \alpha, \beta) = \left( \frac{1}{\Gamma \alpha \beta^\alpha} \right) \left( \frac{1}{x} \right) \exp \left( \alpha \log(x) - \frac{x}{\beta} \right) \mathbb{1}_{(0, \infty)}(x).$$

Donde su soporte no depende de parámetros desconocidos y  $A(\theta) = \frac{1}{\Gamma \alpha \beta^\alpha}$ ,  $B(x) = \frac{1}{x}$ ,  $C_1(\theta) = \alpha$ ,  $D_1(x) = \log(x)$ ,  $C_2(\theta) = \frac{1}{\beta}$  y  $D(x) = x$ , por lo tanto la distribución Gamma pertenece a la familia exponencial.  $\square$

- b) Considera una muestra de  $n$  variables  $X_1, \dots, X_n$  independientes e idénticamente distribuidas como Gamma  $(a, b)$ . Demuestra que las medias aritmética y geométrica,

$$t_1 = \frac{1}{n} \sum_{i=1}^n x_i, \text{ y } t_2 = \left( \prod_{i=1}^n x_i \right)^{\frac{1}{n}}.$$

constituyen un vector de estadísticas suficientes para  $\alpha$  y  $\beta$ . También demuestra que son suficientes para  $(\alpha, \beta)$ .

*Demostración.* Veamos que la densidad conjunta de la muestra es

$$f(\vec{x}; \vec{\theta}) = \prod_{i=1}^n f(x_i; \vec{\theta}) = \left( \prod_{i=1}^n \mathbb{1}_{(0, \infty)}(x) \right) \left( \frac{1}{\Gamma(\alpha) \beta} \right)^n (t_2)^{-n} \exp \left( \alpha \log(t_2^n) - \frac{nt}{\beta} \right).$$

Por el Teorema de la factorización de Fisher concluimos que el vector  $\vec{t} = (t_1, t_2)$  es un vector de estadísticas suficientes de  $(\alpha, \beta)$ .  $\square$

- c) Reparametriza en términos de  $(\mu, \alpha)$  donde la media es  $\mu = \alpha\beta$  y da la expresión de la logverosimilitud de  $\mu, \alpha$ .

**Solución 1** – La reparametrización de la densidad es

$$f(x; \alpha, \beta) = \left( \frac{\alpha^\alpha}{\Gamma \alpha \mu^\alpha} \right) \left( \frac{1}{x} \right) \exp \left( \alpha \left( \log(x) - \frac{x}{\mu} \right) \right) \mathbb{1}_{(0, \infty)}(x),$$

por lo que

$$f(\vec{x}; \vec{\theta}) = \prod_{i=1}^n f(x_i; \vec{\theta}) = \left( \prod_{i=1}^n \mathbb{1}_{(0, \infty)}(x) \right) \left( \frac{\alpha^\alpha}{\Gamma(\alpha) \mu} \right)^n (t_2)^{-n} \exp \left( \alpha \left( \log(t_2^n) - \frac{nt}{\mu} \right) \right),$$

por el Teorema de la factorización de Fisher concluimos que el vector  $\vec{t} = (t_1, t_2)$  es un vector de estadísticas suficientes de  $(\mu, \alpha)$ . Entonces

$$L_u(\vec{\theta}; \vec{t}) = \left( \frac{\alpha^\alpha}{\Gamma(\alpha) \mu} \right)^n \exp \left( \alpha \left( \log(t_2^n) - \frac{nt}{\mu} \right) \right),$$

por lo tanto

$$l(\theta, \vec{t}) = n\alpha \left( \log \left( \frac{\sigma}{\mu} \right) + (\log(t_2)) - \frac{t_1}{\mu} \right) - n \log(\Gamma \alpha).$$

Demuestra que el estimador de momentos de  $\mu$  denotado como  $\tilde{\mu}$  es igual al estimador de máxima verosimilitud de  $\mu$ , denotado por  $\hat{\mu}$ . Demuestra que el estimador de máxima verosimilitud restringido de  $\mu$  dado  $\alpha$  el cual es denotado por  $\hat{\mu}(\alpha)$ , es igual al emv de  $\mu$ .

*Demostración.* Empezaremos por calcular cada uno de los estimadores. El de momentos esta dado por

$$\tilde{\mu} = E[X] = t_1.$$

Puesto que

$$\frac{\partial l}{\partial \mu} = n\alpha(t_1 - \mu),$$

por lo tanto el emv de  $\mu$  es

$$\hat{\mu} = t_1.$$

Por último como  $\hat{\mu}$  es independiente de  $\alpha$  entonces

$$\hat{\mu} = \mu$$

□

Da la logverosimilitud perfil del parámetro de forma  $\alpha$

$$l(\alpha, \hat{\mu}(\alpha); \vec{t}) = n\alpha \left( \log \left( \frac{\alpha}{t_1} \right) + \log(t_2) - 1 \right) - n \log(\Gamma(\alpha)).$$

Da la expresión de la matriz de información de Fisher para  $(\mu, \alpha)$ . Calcula las inormaciones individuales de  $\mu$  y  $\alpha$ .

$$I_{\hat{\mu}\hat{\alpha}} = \begin{pmatrix} \frac{n\hat{\alpha}}{t_1^2} & 0 \\ 0 & n \left( \left( \frac{\Gamma(\hat{\alpha})\Gamma^{(2)}(\hat{\alpha}) - (\Gamma'(\hat{\alpha}))^2}{(\Gamma(\hat{\alpha}))^2} \right) - \frac{1}{\alpha} \right) \end{pmatrix},$$

al ser una matriz diagonal la matriz inversa  $I_{\hat{\mu}\hat{\alpha}}^{-1}$  solo tendra como entrada  $(i, i)$  el inverso de la entrada  $(i, i)$  de la matriz  $I_{\hat{\mu}\hat{\alpha}}$ , luego como las informaciones individuales están dadas por el inverso de la entrada  $(i, i)$  de la matriz  $I_{\hat{\mu}\hat{\alpha}}^{-1}$  entonces concluimos que las informaciones individuales están dadas por las entradas  $(i, i)$  de la matriz  $I_{\hat{\mu}\hat{\alpha}}$ , es decir

$$I_{\hat{\mu}} = \frac{n\hat{\alpha}}{t_1^2},$$

$$I_{\hat{\alpha}} = n \left( \left( \frac{\Gamma(\hat{\alpha})\Gamma^{(2)}(\hat{\alpha}) - (\Gamma'(\hat{\alpha}))^2}{(\Gamma(\hat{\alpha}))^2} \right) - \frac{1}{\alpha} \right).$$

4. Considera una muestra de  $n$  variables aleatorias continuas  $X_1, \dots, X_n$  que son independientes e idénticamente distribuidas como Uniformes en  $(0, \theta)$  con  $\theta > 0$  desconocido. Da un estimador de momentos, el emv y la verosimilitud relativa de  $\theta$ , el intervalo de nivel  $0 \leq c \leq 1$ . Di si existe o no la información de fisher.

El estimador de momentos esta dado por

$$\tilde{\theta} = E[X] = \frac{\theta}{2}.$$

Puesto que la densidad conjunta de las  $X_i$  esta dada por (demostrado tarea 1)

$$f(\vec{x}; \theta) = \left(\frac{1}{\theta}\right)^n \mathbb{1}_{(0, \theta)}(\text{máx}(\vec{x})),$$

entonces con  $t = \text{máx}(\vec{x})$

$$L_U(\theta; T) = \left(\frac{1}{\theta}\right)^n \mathbb{1}_{(0, \theta)}(t),$$

puesto que esto es una función decreciente para  $\theta$  entonces esta se maximizara en el menor valor que  $\theta$  pueda tomar. Ahora hay que recordar que  $\hat{\theta}$  es solo una aproximación al emv que alguna veces resulta serlo pero no es cierto que esto se cumple, ya que por definición

$$\hat{\theta} = \underset{\theta}{\text{máx}} L_u(\theta; t),$$

entonces  $\hat{\theta}$  no tiene que vivir en el espacio parametral. Como  $\hat{\theta} = \sup \{\theta : \theta > t\}$  concluimos que  $\hat{\theta} = t$ .

Ahora (no se si este bien porque la indicadora del denominador es cero, pero...)

$$R(\theta; t) = \frac{\left(\frac{1}{\theta}\right)^n \mathbb{1}_{(0, \theta)}(t)}{\left(\frac{1}{t}\right)^n \mathbb{1}_{(0, t)}(t)} = \left(\frac{1}{\theta t}\right)^n \mathbb{1}_{(0, \theta)}(t),$$

luego  $\left(\frac{1}{\theta t}\right)^n \mathbb{1}_{(0, \theta)}(t) \geq c$  si y sólo si  $\theta > t$  y  $\theta = \frac{1}{\sqrt[n]{ct}}$  por lo tanto

$$IV(c) = \left\{ \theta : \theta = \frac{1}{\sqrt[n]{ct}} \text{ y } \theta > t \right\}.$$

Por último la Información de Fisher es (no se si este bien porque la indicadora es cero)

$$I_{\hat{\theta}} = \frac{n}{\theta^2} \Big|_{\theta=\hat{\theta}} = \frac{n}{t^2}.$$